



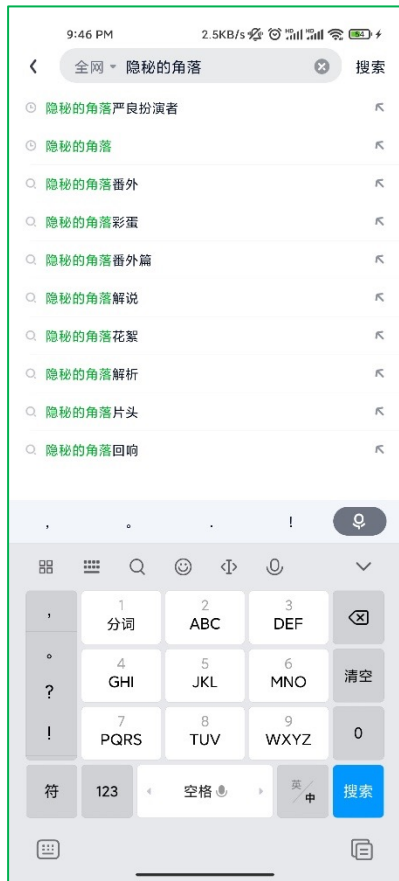
爱奇艺搜索排序算法实践

张志钢



悦 享 品 质

搜索场景



多产品线

爱奇艺、随刻、极速版、TV等

多业务形态

综合搜索、各垂类业务

多数据类型

专辑、短视频、爱奇艺号等

业务目标

- 1 Session CTR
- 1 UCTR
- 1 二次搜索率

搜索效率

用户消费

- 1 用户播放时长
- 1 用户点击次数
- 1 用户互动次数

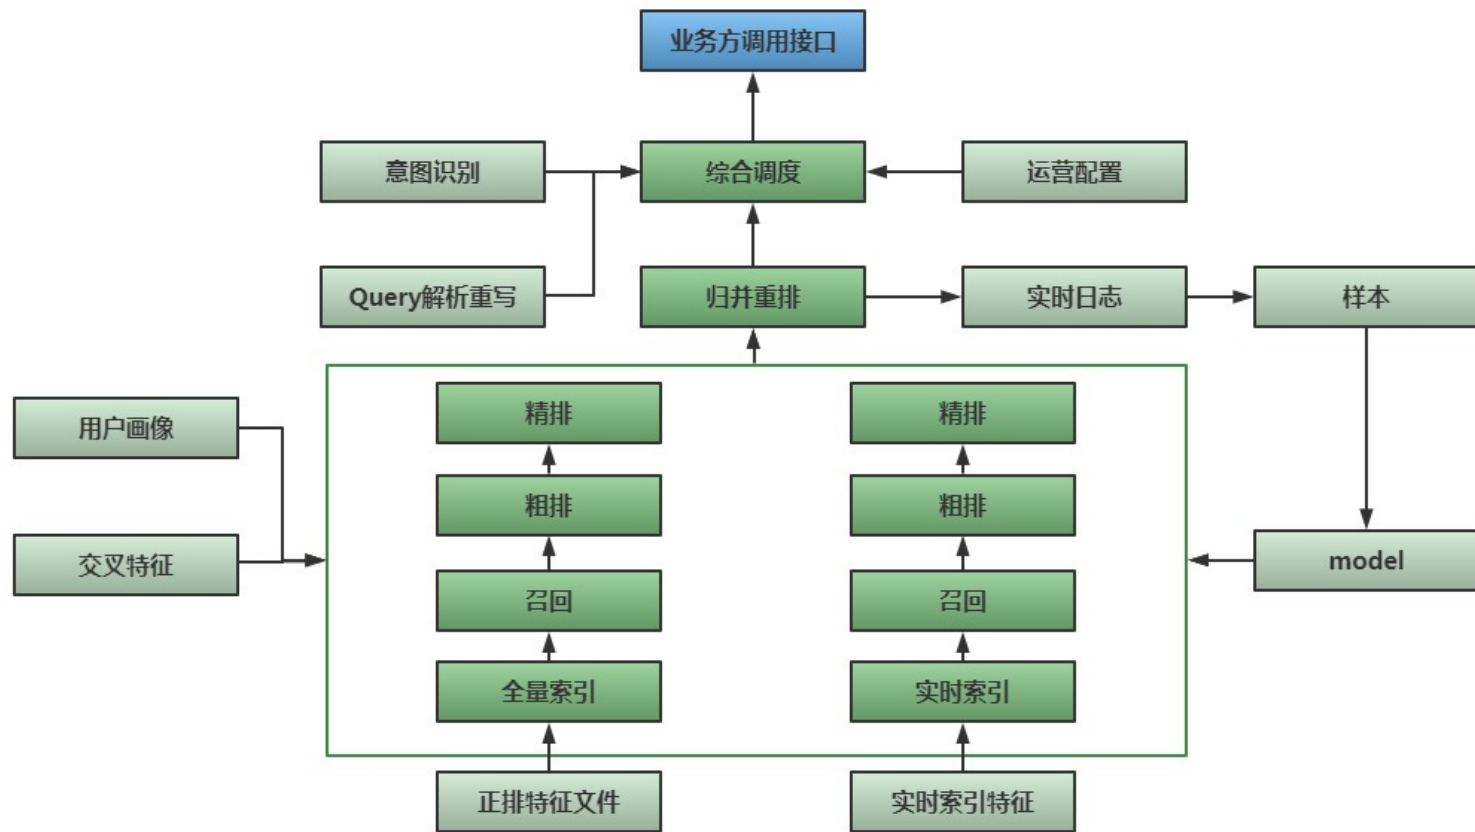
- 1 全网视频
- 1 优质垂类
- 1 爱奇艺号

内容生态


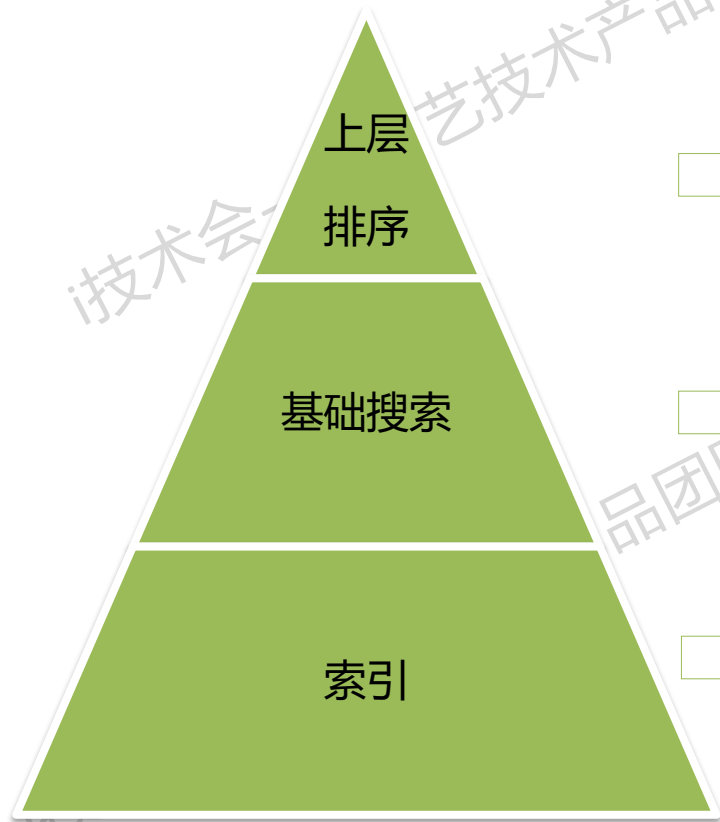
新热多样

- 1 冷启动
- 1 时效性
- 1 多样性

整体架构




算法策略框架



- 粗排
- 精排
- Rerank

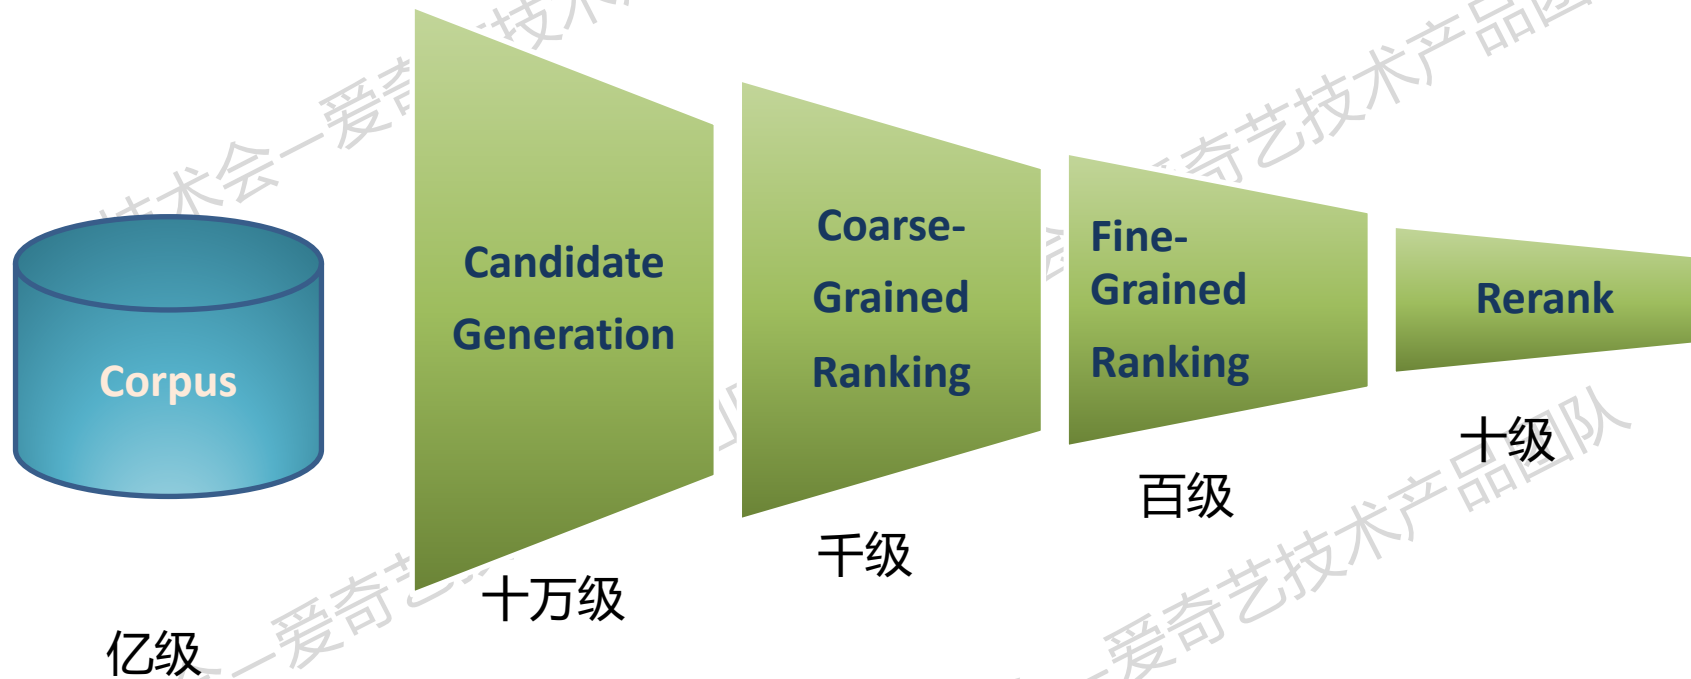


- 召回
- 时效性、质量等策略调权

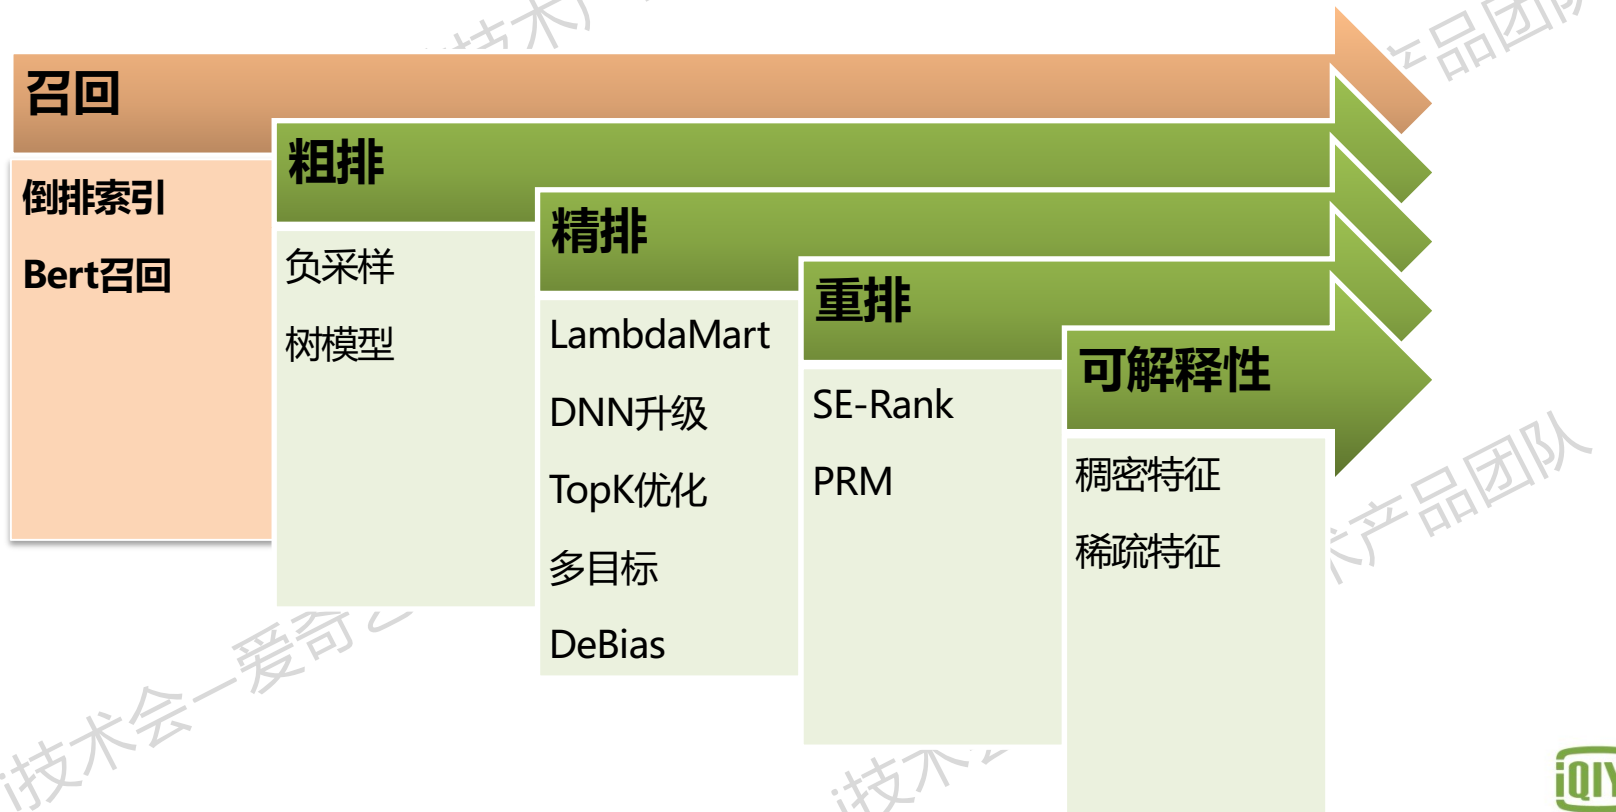


- 分级
- 分片

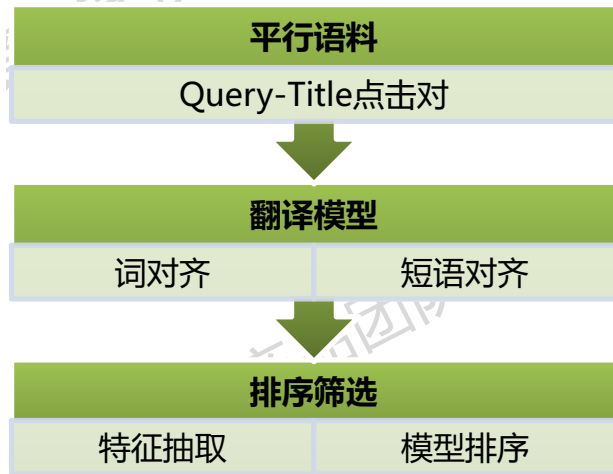
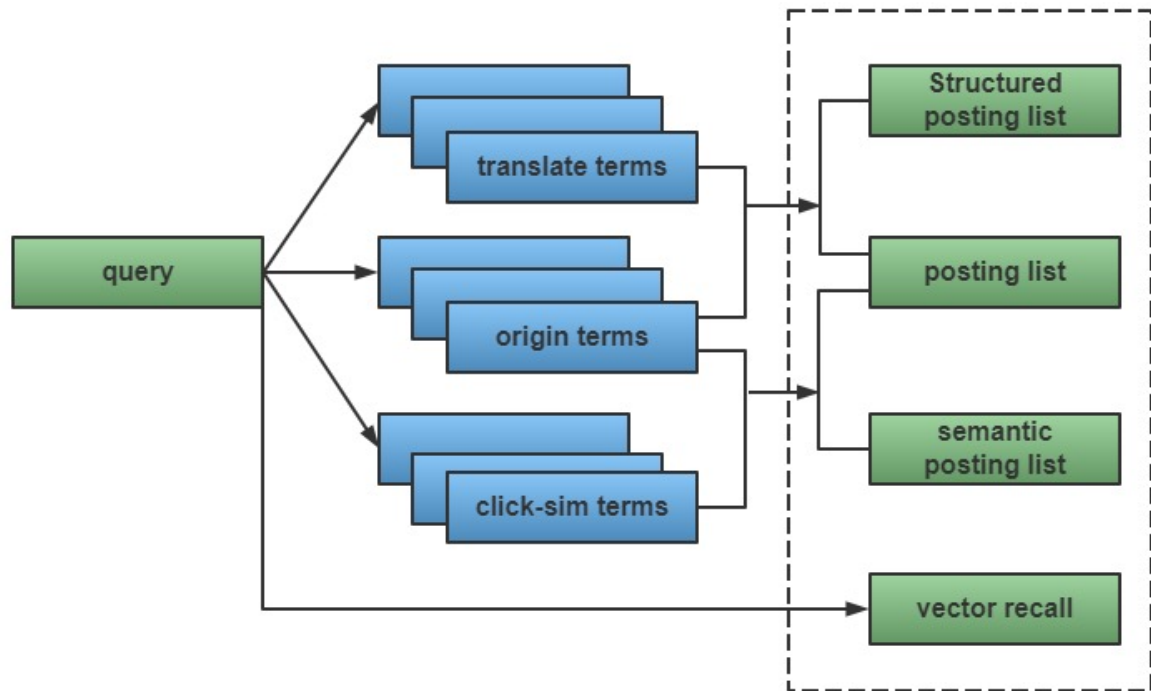
排序流程



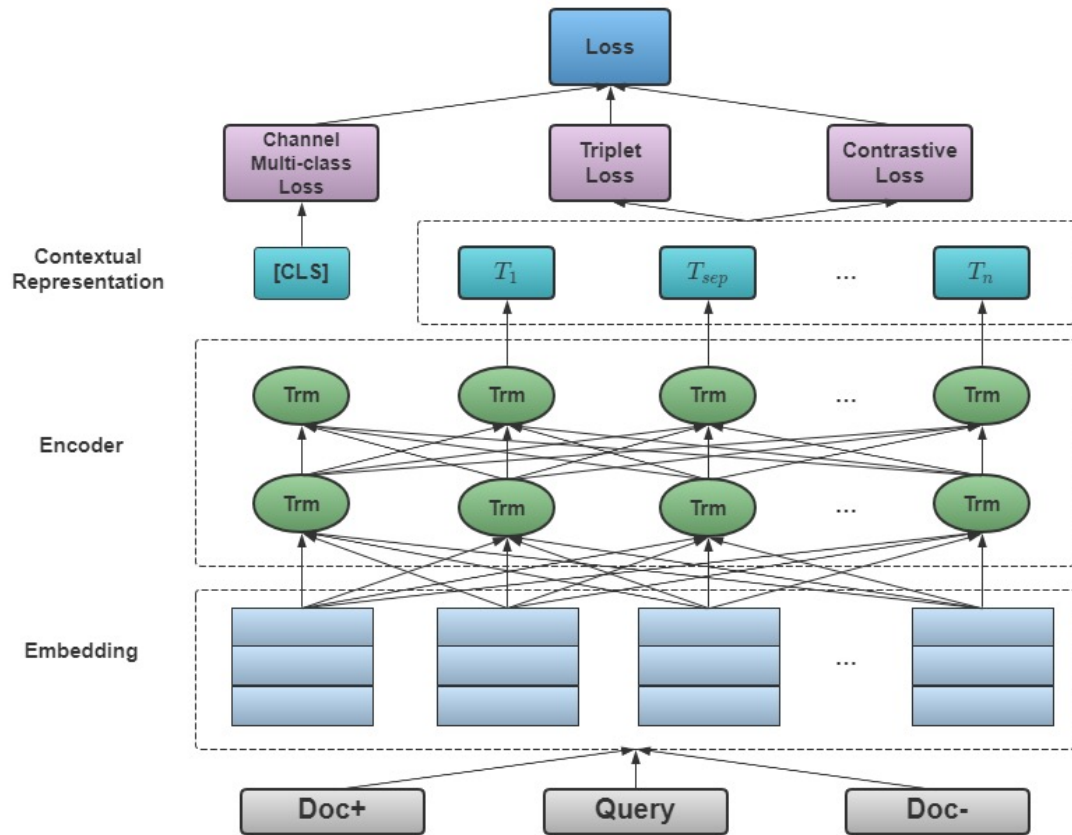
提要



召回阶段



Bert召回



➤ 样本构建

➤ 输入特征

➤ 训练Loss

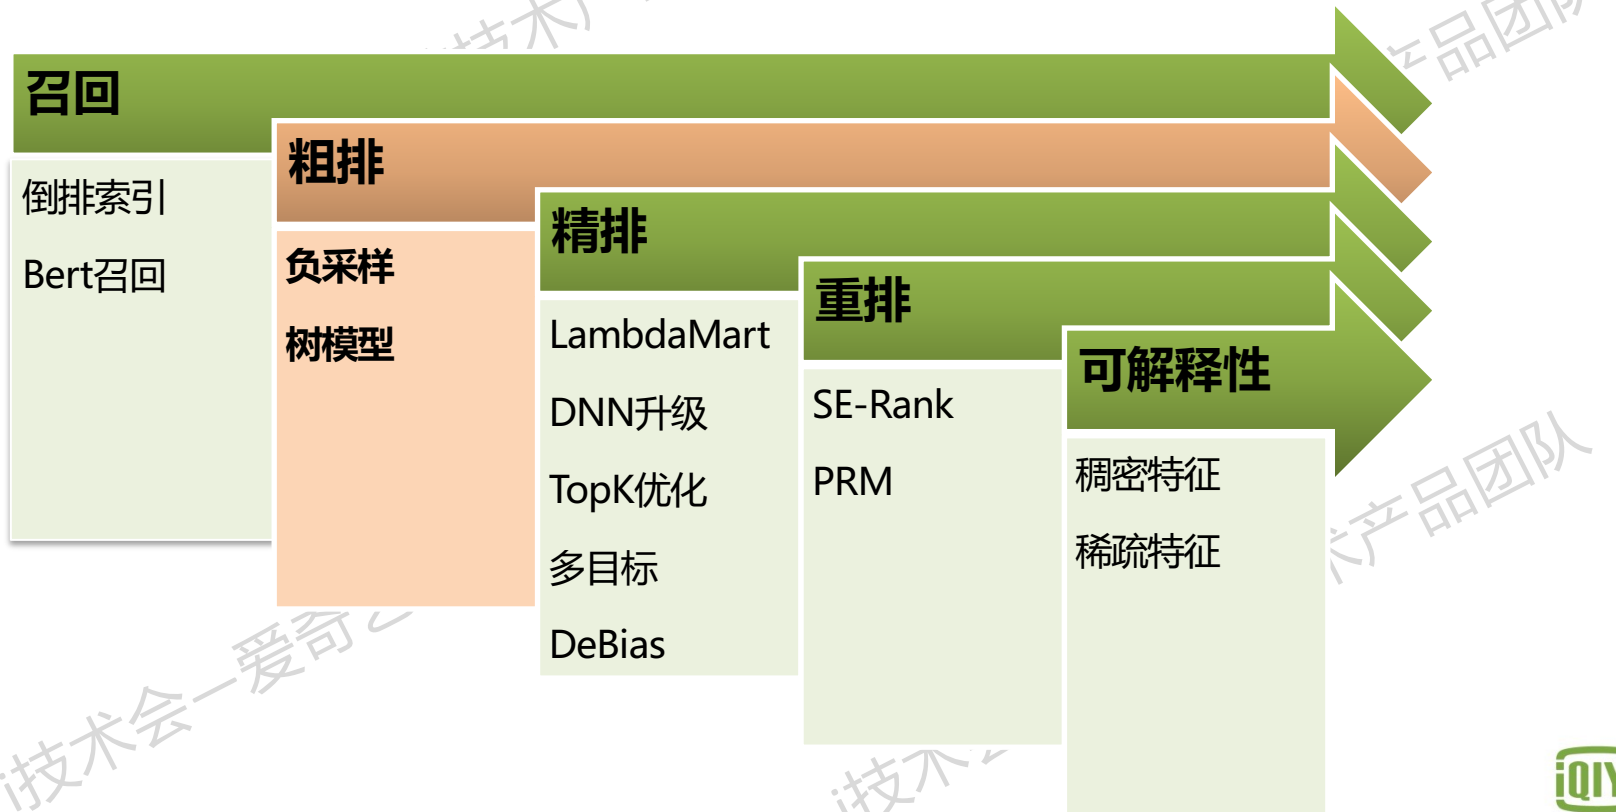
➤ Triplet Loss

➤ Contrastive Loss

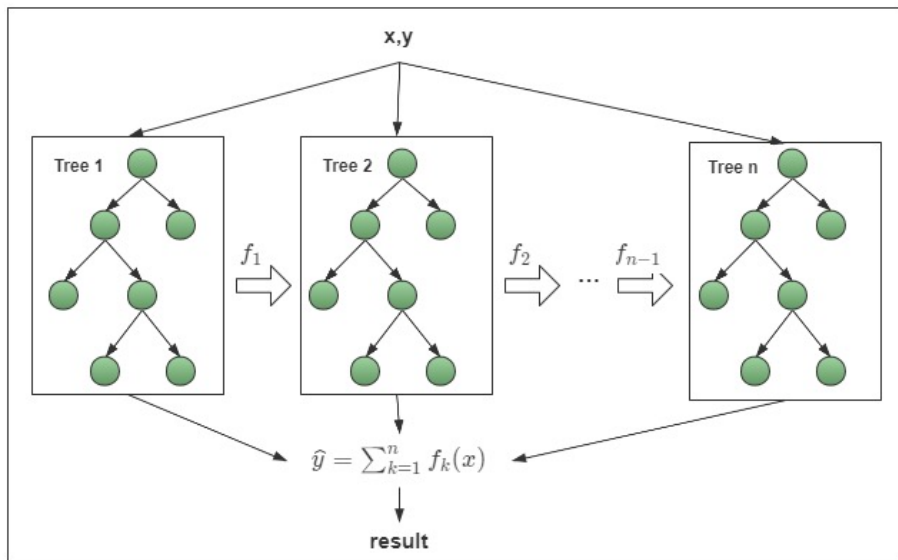
➤ Channel Multi-class Loss

➤ 在线服务

提要



粗排阶段



➤ 样本构建

➤ 正样本

➤ 用户点击

➤ 负样本

➤ 重要特征

➤ Doc质量特征

➤ 交叉特征

➤ 频道提权特征

➤ 时效性特征

➤ 模型

➤ XGBoost

➤ 加权交叉熵

提要

召回

倒排索引

Bert召回

粗排

负采样

树模型

精排

LambdaMart

DNN升级

TopK优化

多目标

DeBias

重排

SE-Rank

PRM

可解释性

稠密特征

稀疏特征

Learning to Rank

➤ Point-wise

$$L_{pointwise} = \frac{1}{N} \sum_{i=1}^N (f_{\theta}(d_i) - y(d_i))^2 \quad L = -\frac{1}{m} \sum_{i=1}^m y_i * \log(\hat{y}_i)$$

➤ Pair-wise

$$L_{pairwise} = \sum_{y(d_i) > y(d_j)} \max(0, 1 - (f_{\theta}(d_i) - f_{\theta}(d_j)))$$

➤ List-wise

$$L_{listwise} = \sum_{y(d_i) > y(d_j)} \log(1 + (e^{f_{\theta}(d_i) - f_{\theta}(d_j)})) * |\Delta NDCG|$$

RankNet & LambdaMart

➤ RankNet

$$S = f(x; w)$$

$$S_i = f(x_i; w), S_j = f(x_j; w)$$

$$p_{ij} = \frac{e^{\sigma(s_i - s_j)}}{1 + e^{\sigma(s_i - s_j)}} = \frac{1}{1 + e^{(-\sigma(s_i - s_j))}}$$

$$L_{ij} = -\bar{P}_{ij} \log P_{ij} - (1 - \bar{P}_{ij}) \log(1 - P_{ij})$$

$$P_{ij} = \frac{1}{2}(1 + s_{ij}) \quad s_{ij} = +1, 0, -1$$

$$\lambda_{ij} = \sigma\left[\frac{1}{2}(1 - s_{ij}) - \frac{1}{1 + e^{\sigma(s_i - s_j)}}\right] \quad s_{ij} = 1$$

➤ LambdaMart

$$\lambda_{ij} = -\frac{1}{1 + e^{\sigma(s_i - s_j)}} |\Delta Z_{ij}|$$

➤ LambdaRank重新定义梯度

➤ 训练框架采用MART

➤ Label构造

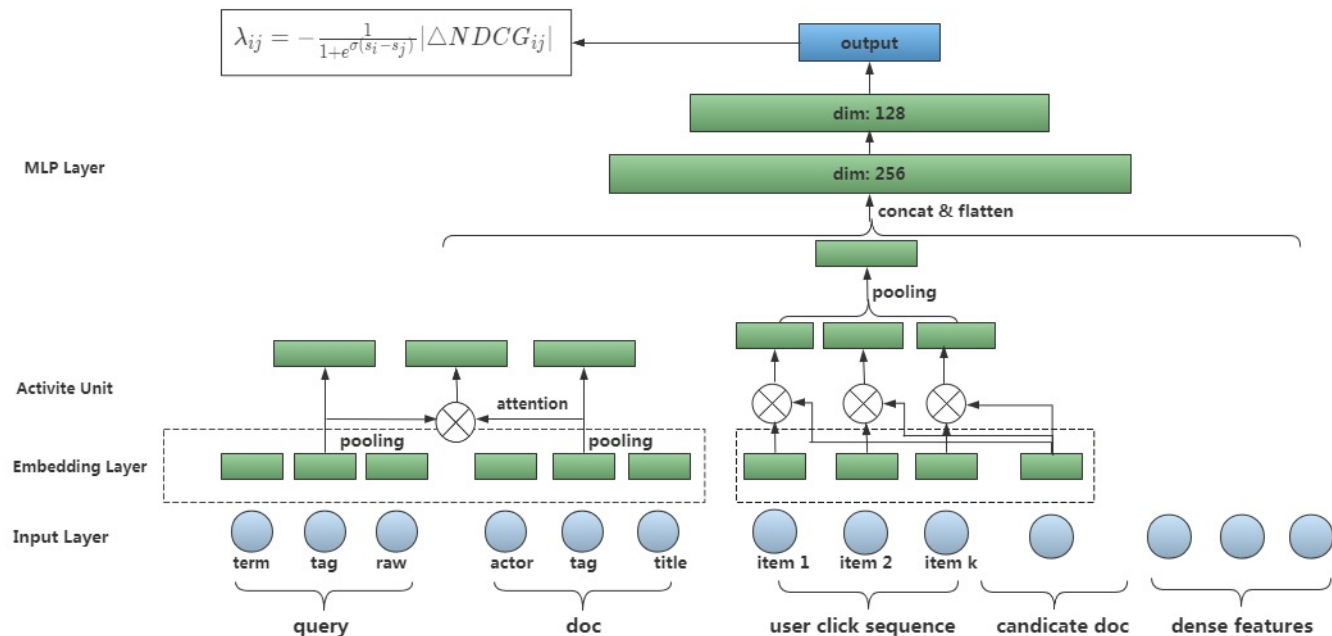
➤ 采用点击质量划分0~3共4档

➤ 适用于排序场景

➤ 对比大小而非绝对值

➤ 对于正负样本比例不敏感

LambdaRank DNN



➤ 样本采样

➤ 训练方式为List-wise

➤ 新增稀疏特征

➤ Query

➤ Doc

➤ User Profile

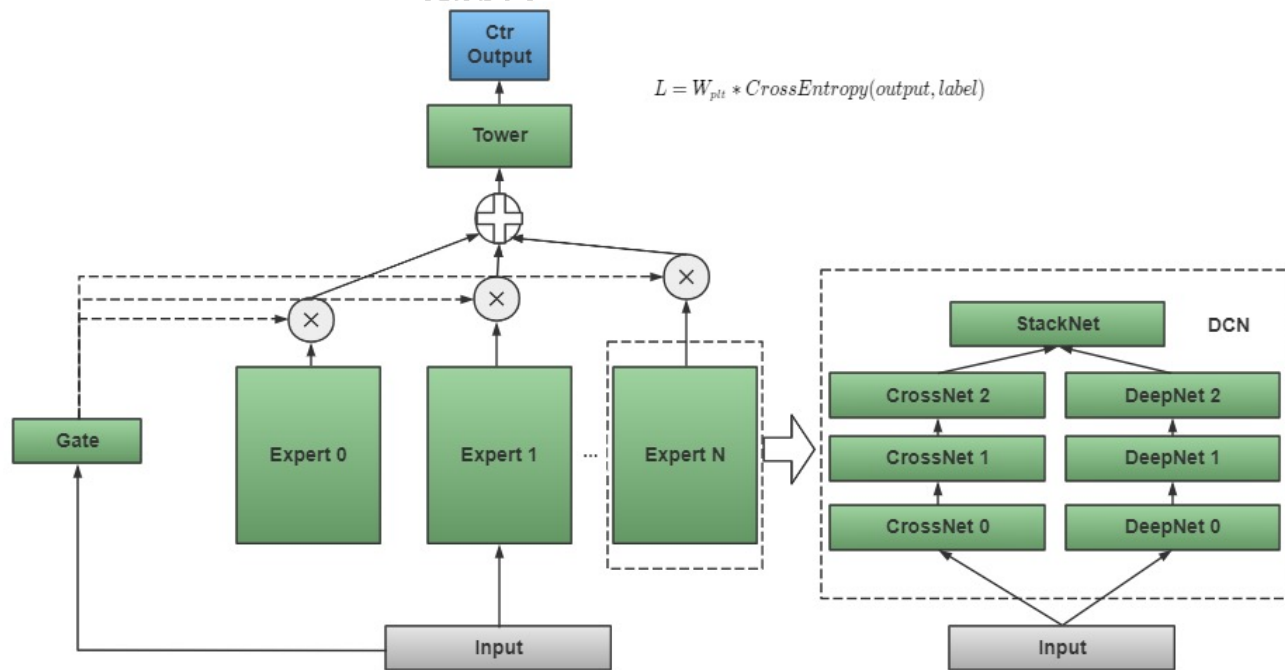
➤ Loss

➤ LambdaRank

➤ 离线评估

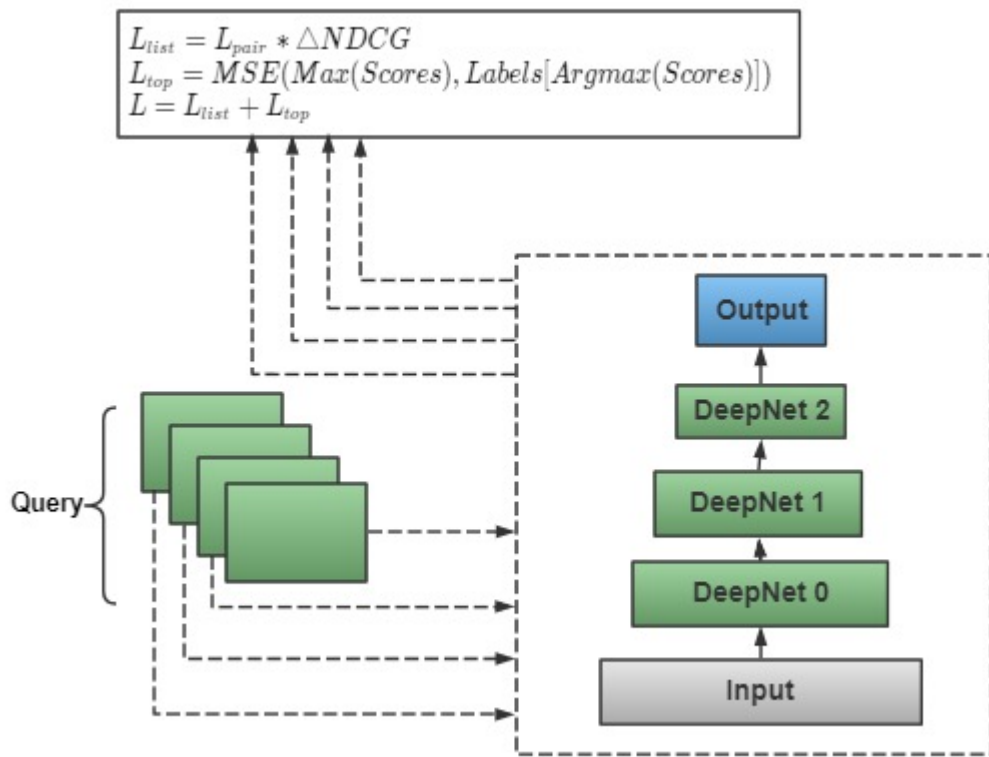
➤ NDCG@5

TopK Optimization – Hot Query



- 扩充大量头部样本
- 单目标加权
- 训练方式Pointwise
- 采用混合专家网络
- 新增ID特征

TopK Optimization – Longtail Query



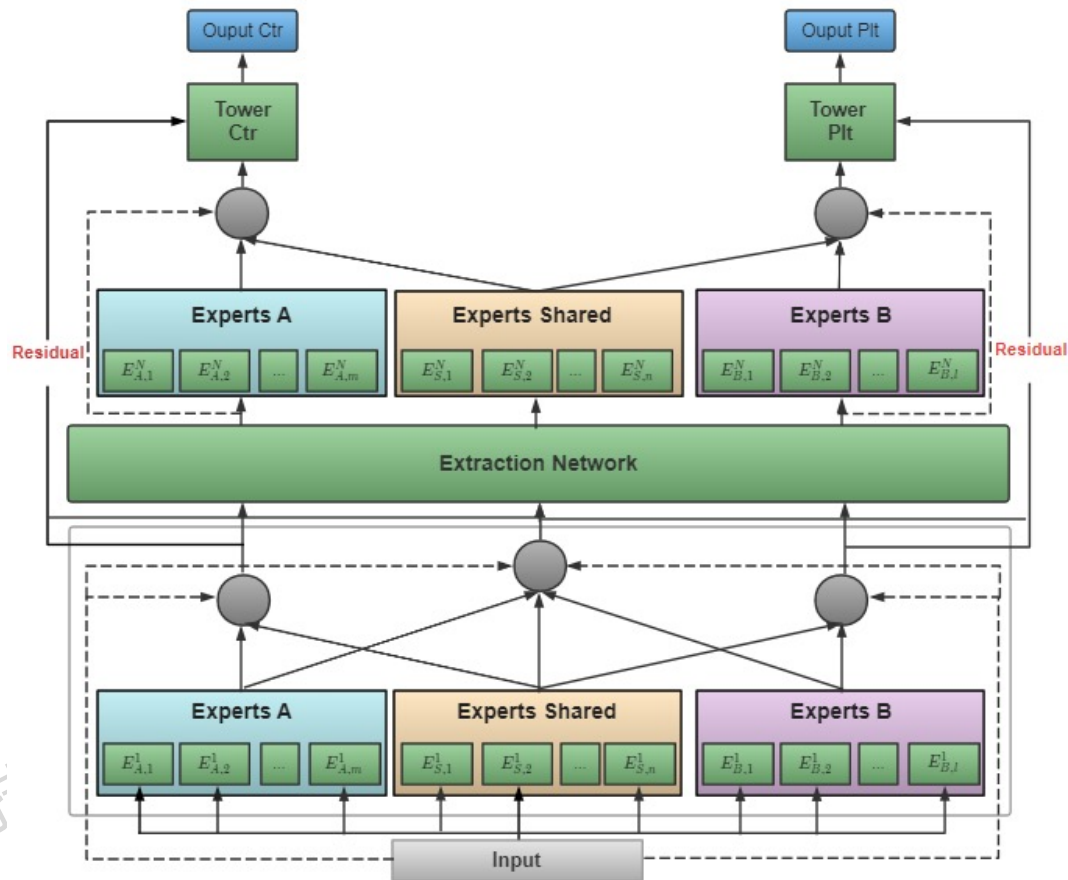
➤采用Listwise方式训练

➤限制单条样本下Doc数最小为2

➤Label采用点击质量

➤加大对Top1排序以及Label绝对值偏差的惩罚

Residual PLE



➤ 时长进行Log平滑处理

➤ Loss采用
 $CE(Ctr) + \alpha * MSE(Plt)$


➤ 单个Expert采用DCN结构

➤ 双层PLE，任务塔加入首层残差

➤ 线上融合：
 $Norm(P_{Ctr}) * (Norm(P_{Plt}) + Bias)$

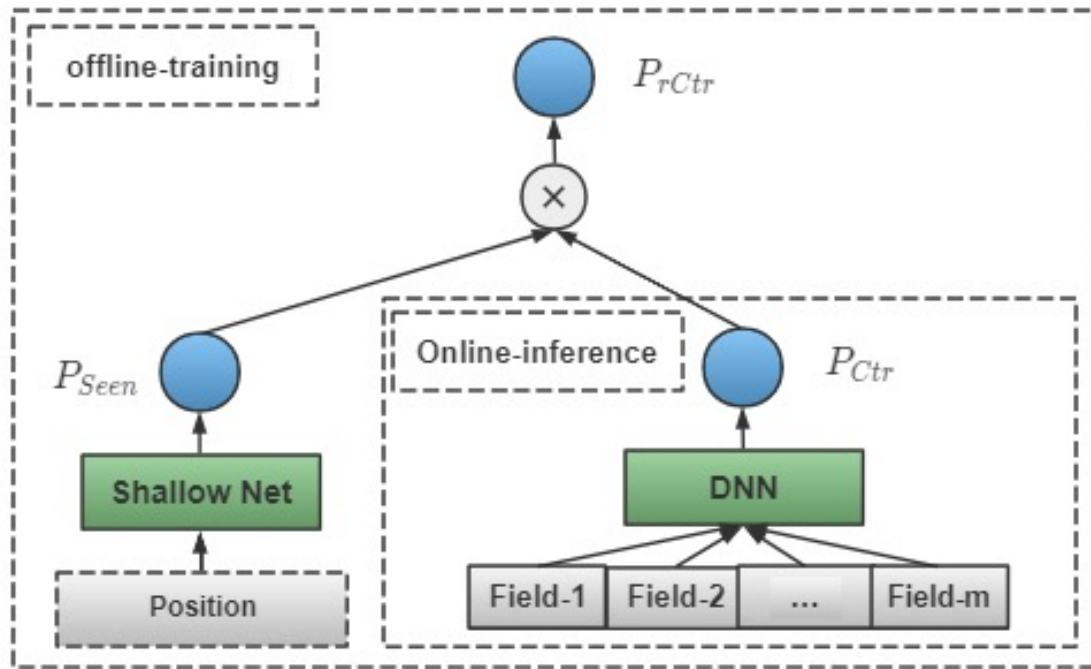
Position Bias

点展分布



- Position及少量特征，构建单独塔，输出加入到模型Wide部分
- Drop-out 0.15
- 线上固定Position特征值为1
- AB指标负向

Position Bias



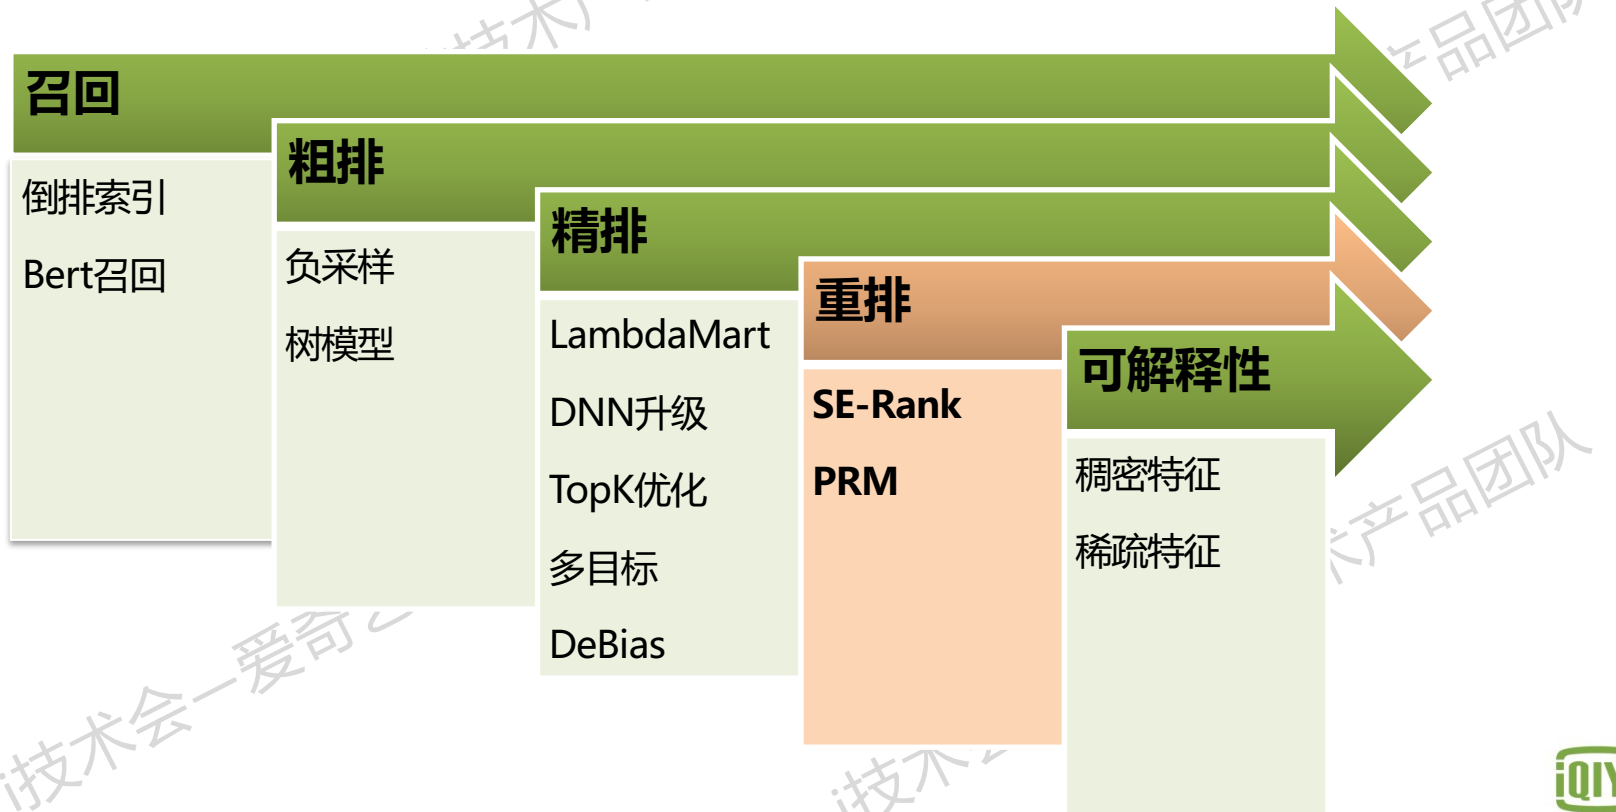
➤ Position及少量特征，构建单独塔，建模被用户看到概率 P_{Seen}

➤ 真实点击率预估值

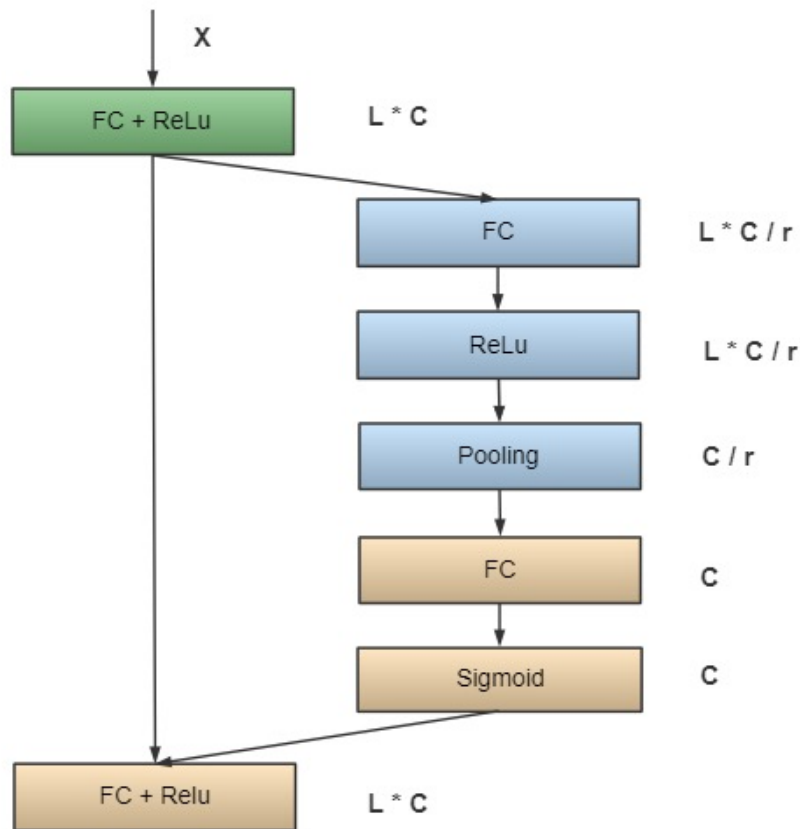
$$P_{rCtr} = P_{Seen} * P_{Ctr}$$

➤ 线上预估只取 P_{Ctr}

提要



重排阶段 - SE-Rank



➤目标

➤建模上下文感知

➤样本采样

➤List_size $\in [2, MaxLen]$

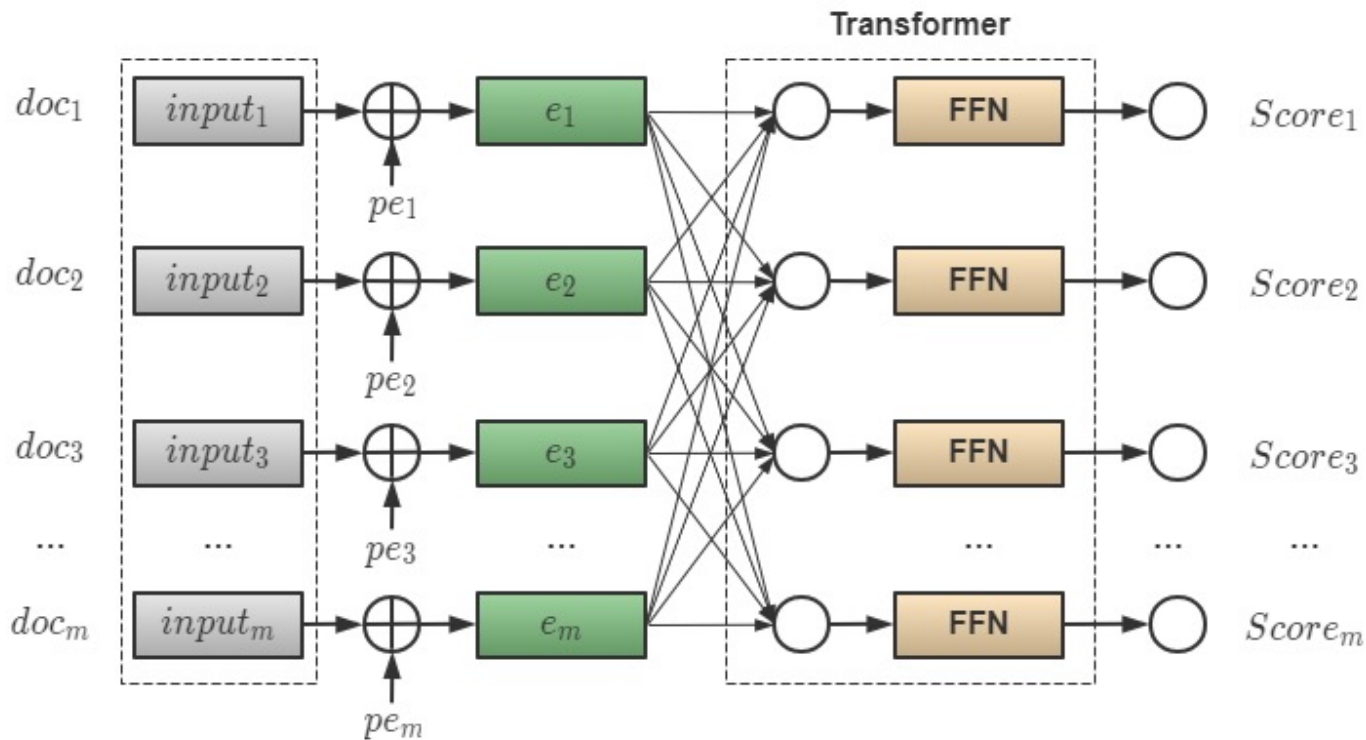
➤训练方式为List-wise

➤模型结构

➤加入SE-Block

➤Field-wise

重排阶段 - PRM



➤ Listwise训练

➤ 模型结构

➤ Doc特征表示

➤ Transformer结构

➤ 离线评估

➤ NDCG

提要

召回

倒排索引

Bert召回

粗排

负采样

树模型

精排

LambdaMart

DNN升级

TopK优化

多目标

DeBias

重排

SE-Rank


PRM

可解释性

稠密特征


稀疏特征

可解释性 - 稠密特征





- 采用LIME框架
 - 局部可解释
- 特征填充
 - 稀疏特征填充为默认值
- 特征重要性
 - 实时交叉特征
 - 实时Query统计特征

Feature Importance Figure



可解释性 - 稀疏特征



- 全局可解释性
- 精排输入层加入简化版SE-Block
- 可解释性
 - Point-wise的SE-Block加入到精排有稀疏特征可解释的作用

Q&A

谢谢！



悦 享 品 质